AI Agent Challenge 2026

Guida Strategica ai Modelli — Anomaly Detection

12 Marzo 2026 | 15:30 – 21:30 CET

🗺 Contesto Challenge: Reply Mirror

Scenario: frode finanziaria in evoluzione (MirrorPay, 2087). 5 livelli con dataset di complessità crescente.

Output atteso: file .txt con Transaction ID fraudolenti (uno per riga). Output invalido se < 15% fraud trovati, nessuno, o tutti.

Scoring: accuratezza + stabilità temporale + adattabilità + efficienza/costo/latenza.

Dati extra disponibili: Transactions, Locations GPS, Users, Conversations (SMS), Messages (email) — ideali per LLM/agent.

Asimmetria costi: falso positivo (blocca legittimo) = danno reputazionale. Falso negativo (lascia passare frode) = danno finanziario.

Budget Disponibile

Fase	Budget	Modelli raccomandati	Strategia
Training 1-3	~$40 totali	Gemini 2.0 Flash Lite, DeepSeek R1 Distill 70B	Itera velocemente, debug del pipeline, no sprechi
Evaluation 1-3	Incluso nei $40	GPT-4.1 Mini o DeepSeek R1 Distill 32B	Una sola submission: testa prima! Usa un mid-tier per risparmiare
Training 4-5	~$120 totali	Gemini 2.5 Flash, Qwen3 32B	Dataset più complessi: usa modelli più capaci per il training
Evaluation 4-5	Incluso nei $120	DeepSeek R1 o o4-mini	Punta al massimo: qui si decide il ranking finale

★ Regola d'oro: usa il 70% del budget su training e 30% su evaluation. Per le evaluation, una sola chance — non rischiare con modelli non testati.

Tier 1 — Best Score (Evaluation finale)

Usa questi modelli SOLO per le submission di evaluation finale. Potenti ma costosi.

Modello	Model String	Costo Token	Quando usarlo
DeepSeek R1	deepseek/deepseek-r1	$$$$	Reasoning esplicito su pattern anomali, ottimo per fraud
OpenAI o4-mini	openai/o4-mini	$$$	Miglior rapporto qualità/costo per classification finale
OpenAI o3	openai/o3	$$$$$	Massima qualità assoluta, usa solo se hai budget avanzato
Gemini 2.5 Flash	google/gemini-2.5-flash	$$	Context window enorme, ottimo se i dataset sono grandi
Qwen3 235B A22B	qwen/qwen3-235b-a22b	$$$	MoE: molto capace, più economico della taglia suggerisce

Llama 4 Maverick	meta-llama/llama-4-maverick	$$	Forte reasoning, buona capacità analitica, meno costoso

Tier 2 — Bilanciato (Training e test)

Ideali per iterare sul training senza bruciare budget. Buona qualità a costo contenuto.

Modello	Model String	Costo Token	Quando usarlo
DeepSeek R1 Distill 70B	deepseek/deepseek-r1-distill-llama-70b	$$	R1 distillato: buon reasoning a metà prezzo
DeepSeek R1 Distill 32B	deepseek/deepseek-r1-distill-qwen-32b	$$	Versione più leggera, ottima per iterare veloce
GPT-4.1 Mini	openai/gpt-4.1-mini	$	Economico, ottima instruction following
Gemini 2.0 Flash	google/gemini-2.0-flash-001	$	Veloce, buono per test rapidi e debug
Llama 3.3 70B Instruct	meta-llama/llama-3.3-70b-instruct	$	Affidabile, open, ben conosciuto
Qwen3 32B	qwen/qwen3-32b	$	Ottimo per iterare, capace sul reasoning
Mistral Large 2411	mistralai/mistral-large-2411	$$	Solido su task analitici strutturati

Tier 3 — Ultra cheap (Subtask e orchestrazione)

Per subtask semplici nell'architettura multi-agente: parsing, formatting output, routing tra agenti.

Modello	Model String	Costo Token	Quando usarlo
Gemini 2.0 Flash Lite	google/gemini-2.0-flash-lite-001	$	Già nel tuo stack! Cheapissimo, velocissimo
GPT-4.1 Nano	openai/gpt-4.1-nano	$	Il più economico di OpenAI, per task banali
Qwen3 8B	qwen/qwen3-8b	¢	Micro ma capace, per routing/classificazione semplice
Llama 3.2 3B	meta-llama/llama-3.2-3b-instruct	¢	Parsing e formattazione output
Mistral Nemo	mistralai/mistral-nemo	¢	Buono per output cleaning e normalizzazione

Matrice Decisionale — Quale modello scelgo?

Usa questa tabella come riferimento rapido durante la challenge.

Scenario	Modello consigliato	Motivazione
Voglio il miglior score possibile	deepseek/deepseek-r1 o openai/o4-mini	Usa per evaluation finale. R1 per reasoning esplicito, o4-mini se budget è limitato
Ho poco budget rimasto	google/gemini-2.5-flash o llama-4-maverick	Buona qualità a costo inferiore rispetto ai top tier
Sto testando il pipeline (training)	deepseek/deepseek-r1-distill-llama-70b	R1 distillato: stesso stile di reasoning, metà del costo
Sto iterando velocemente (debug)	google/gemini-2.0-flash-lite-001	Già nel tuo stack, quasi gratuito, ideale per cicli rapidi
Il dataset è molto grande	google/gemini-2.5-flash	Context window enorme: processa più righe in un singolo prompt
Devo fare routing/parsing nell'agent	openai/gpt-4.1-nano o qwen3-8b	Subtask semplici: non sprecare token costosi su orchestrazione
Evaluation 1-3 (budget $40 totale)	openai/gpt-4.1-mini o r1-distill-32b	Risparmia qui per avere più budget sui dataset 4-5 più difficili
Evaluation 4-5 (budget $120 disponibile)	deepseek/deepseek-r1 o openai/o4-mini	Massimizza la qualità: questi dataset sbloccano il ranking finale
Il modello dà errori di formato output	openai/gpt-4.1-mini	Eccellente instruction following per output strutturati (.txt formattato)
Voglio reasoning chain esplicita	deepseek/deepseek-r1	Mostra il ragionamento passo passo: utile per capire falsi positivi

Modelli da Evitare per questo Task

Questi modelli non sono adatti ad anomaly detection — non sprecare token.

Categoria	Esempi e motivazione
Modelli RP / creative	MythoMax, NeverSleep Lumimaid, Noromaid, TheDrummer — ottimizzati per roleplay, non analisi
Modelli coding-only	CodeLLaMa 7B Solidity, KAT-Coder — troppo specializzati, nessun vantaggio su fraud detection
Modelli troppo piccoli	LFM2-2.6B, Llama 3.2 1B — insufficienti per ragionamento complesso su anomalie
Search-optimized	Perplexity Sonar / Sonar Deep Research — ottimizzati per web search, inutili per classification

Tips Strategici per la Challenge

1. Non usare mai un modello Tier 1 in training — è uno spreco puro di budget.
2. Il tuo stack già usa gemini-2.0-flash-lite: mappa su google/gemini-2.0-flash-lite-001 via OpenRouter.
3. Risolvi il Langfuse 404 PRIMA delle 15:30 — ogni submission senza Session ID è invalidata.
4. Per i dataset 4-5 hai $120: spendi bene, ma non aver paura di usare R1 o o4-mini per l'evaluation.
5. Il widget token sulla challenge page è il tuo cruscotto — tienilo d'occhio costantemente.
6. Struttura multi-agente: usa modelli cheap per orchestrazione e routing, pesanti solo per il giudizio finale.

7. Output invalido se riporti 0 transazioni, tutte le transazioni, o meno del 15% dei fraud reali — verifica sempre prima di submission.

In bocca al lupo! May the best agent win! 🐟